SEMINARIO DE BIG DATA Y CIENCIAS DE DATOS

CRISTHIAN CAMILO BALAGUERA SOTO - 88913 DANIEL MAURICIO GORDILLO ALVAREZ - 89400

PROFESOR

ELIAS BUITRAGO BOLIVAR

UNIVERSIDAD ECCI

BOGOTÁ D.C., COLOMBIA

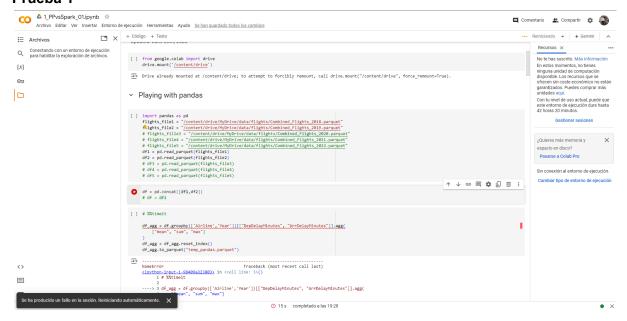
Laboratorio 2

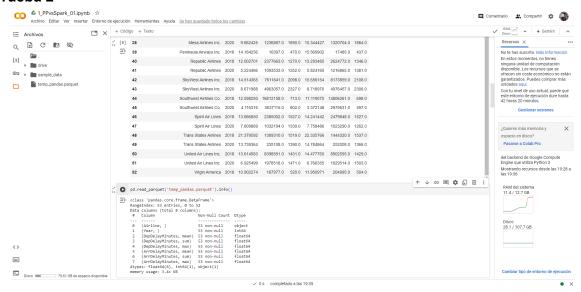
Introducción

Este laboratorio tiene como objetivo evaluar la eficiencia de diversas librerías de Python para el procesamiento de las librerías: Pandas, Polars, Spark y Dask. El propósito es determinar cuál de estas librerías puede manejar la mayor cantidad de datos en Google Colaboratory sin que la memoria RAM se sature y provoque el reinicio del entorno. Se experimentaran con cada librería y el conjunto de datos proporcionado, identificando cuál es la más eficiente en términos de uso de memoria RAM y capacidad de procesamiento de archivos.

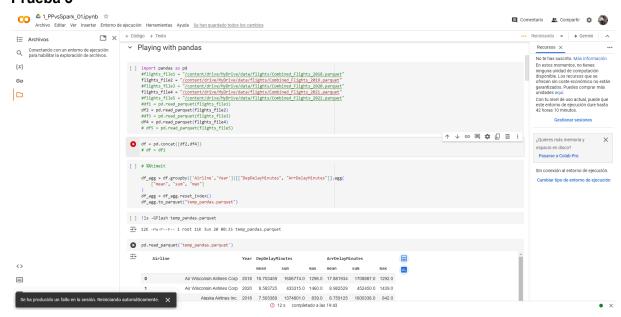
Método Pandas	# de prueba	Datos utilizados	Resultados
	Prueba 1	flights_file1 flights_file2 df1 df2	42 segundos Limite de RAM alcanzado en el paso 3
	Prueba 2	flights_file1 flights_file3 df1 df3	43 segundos Proceso ejecutado con éxito RAM : 11.4 Gb Disco : 28.1 Gb
	Prueba 3	flights_file2 flights_file4 df2 df4	47 segundos Limite alcanzado en el paso 2
	Prueba 4	flights_file2 flights_file5 df2 df5	43 segundos Limite alcanzado en el paso 3

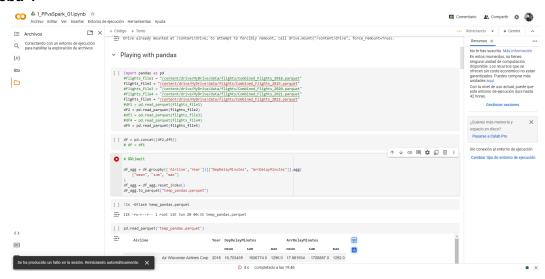
Prueba 1



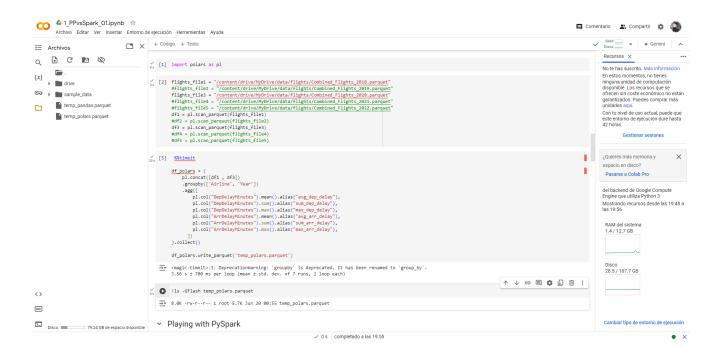


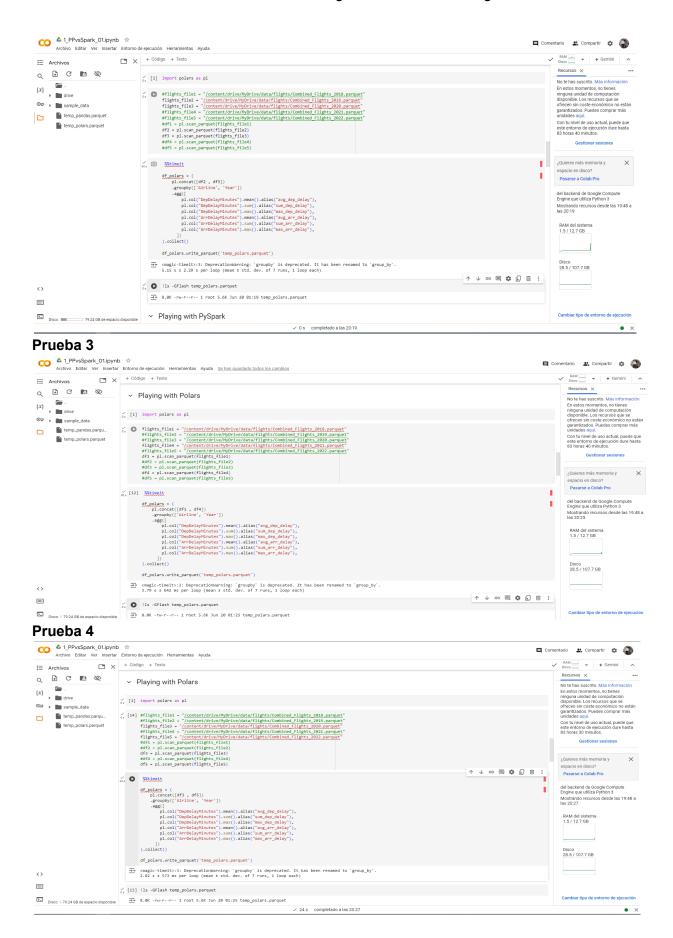
Prueba 3





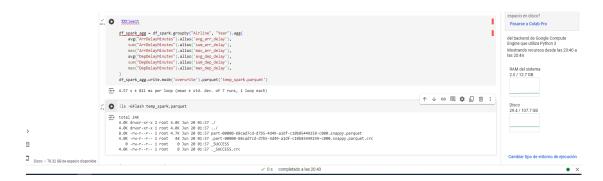
	# de prueba	Datos utilizados	Resultados
Método Polars	Prueba 1	flights_file1 flights_file3 df1 df3	42 segundos Proceso ejecutado con éxito RAM: 1.4 Gb Disco: 28.5 Gb
	Prueba 2	flights_file2 flights_file3 df2 df3	44 segundos Proceso ejecutado con éxito RAM : 1.5 Gb Disco : 28.5 Gb
	Prueba 3	flights_file1 flights_file4 df1 df4	30 segundos Proceso ejecutado con éxito. RAM:1.5 Gb Disco: 28.5 Gb
	Prueba 4	flights_file3 flights_file5 df3 df5	24 segundos Proceso ejecutado con éxito. RAM:1.5 Gb Disco: 28.5 Gb

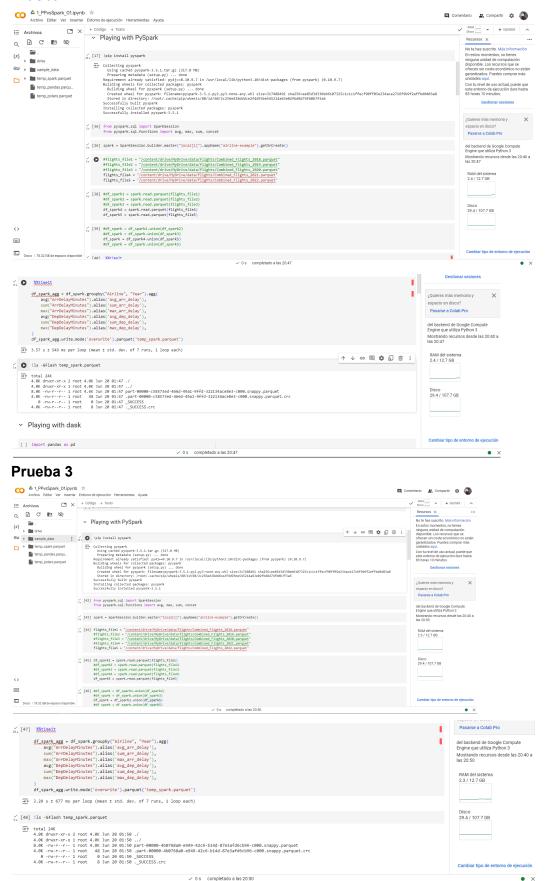


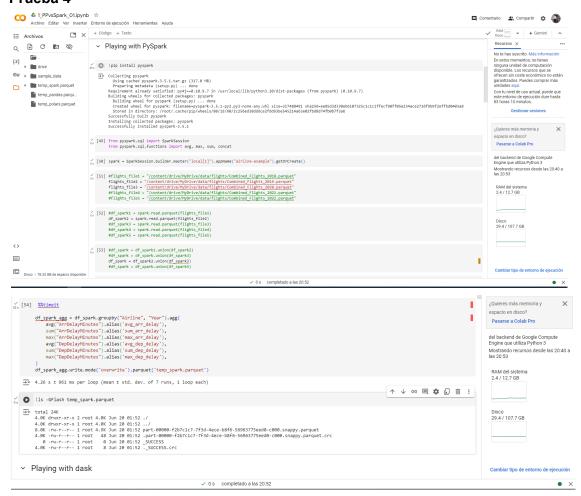


Método PySpark	# de prueba	Datos utilizados	Resultados
	Prueba 1	flights_file3 flights_file4 df3 df4	46 segundos Proceso ejecutado con éxito RAM: 2.0Gb Disco: 29.4 Gb
	Prueba 2	flights_file4 flights_file5 df4 df5	29 segundos Proceso ejecutado con éxito RAM : 2.3 Gb Disco : 29.4 Gb
	Prueba 3	flights_file1 flights_file5 df1 df5	26 segundos Proceso ejecutado con éxito RAM : 2.3 Gb Disco : 29.4 Gb
	Prueba 4	flights_file2 flights_file3 df2 df3	33 segundos Proceso ejecutado con éxito RAM : 2.3 Gb Disco : 29.4 Gb



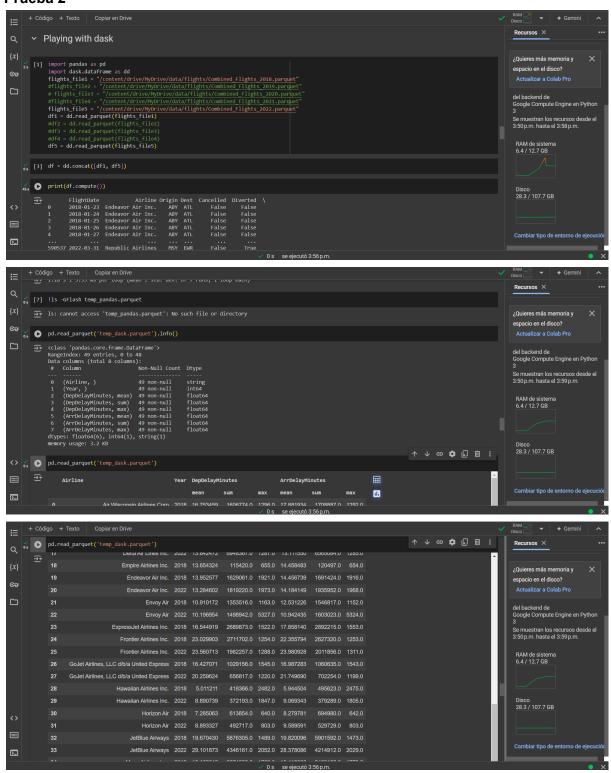


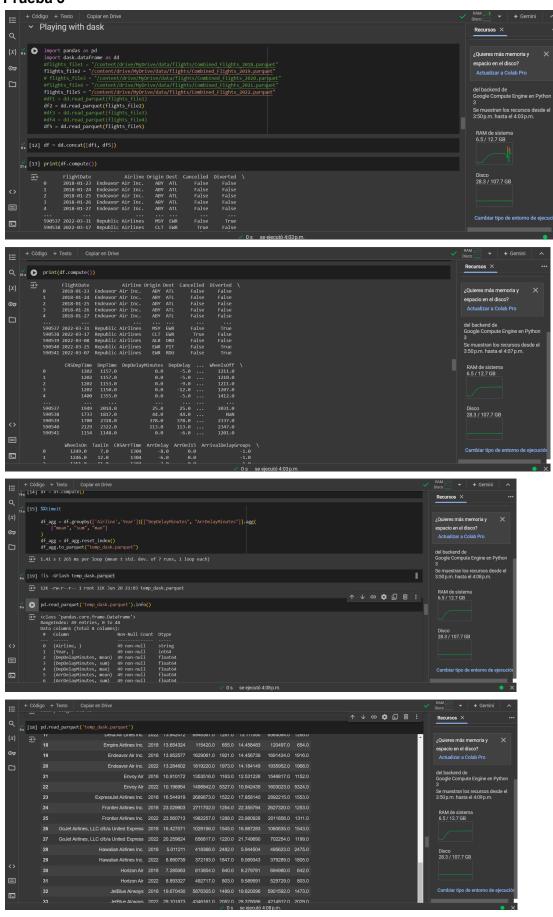


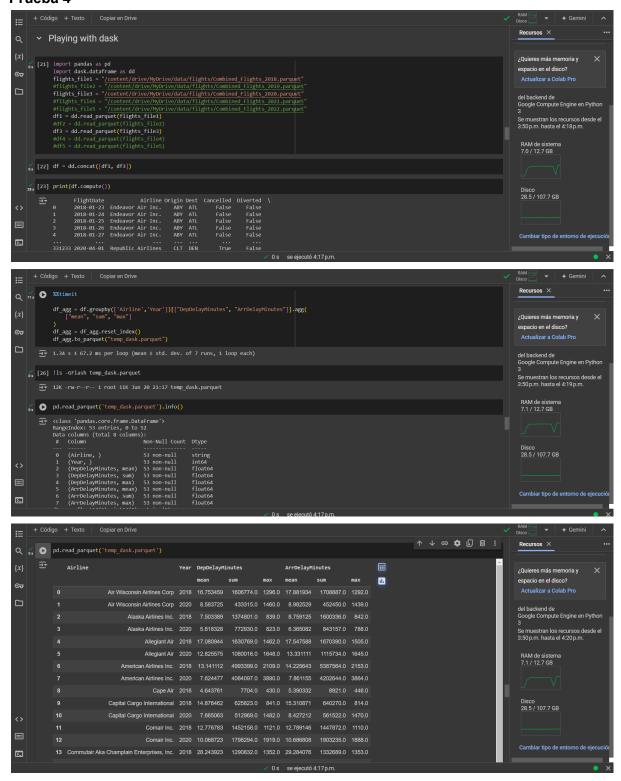


Método Dask	# de prueba	Datos utilizados	Resultados
	Prueba 1	flights_file2 flights_file4 df3 df4	29 segundos Limite de RAM alcanzado en el paso 3
	Prueba 2	flights_file1 flights_file5 df4 df5	77 segundos Proceso ejecutado con éxito RAM : 6.4 Gb Disco : 28.3 Gb
	Prueba 3	flights_file2 flights_file5 df2 df5	51 segundos Proceso ejecutado con éxito RAM : 6.5 Gb Disco : 28.3 Gb
	Prueba 4	flights_file1 flights_file3 df1 df3	65 segundos Proceso ejecutado con éxito RAM : 7.1 Gb Disco : 28.5 Gb

```
△ 1 PPvsSpark_01.ipynb ☆
           Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda <u>No se pueden guardar los cambios</u>
        + Código + Texto Copiar en Drive
           import pandas as pd
Q
                import dask.dataframe as dd
# flights file1 = "/content/drive/MyDrive/data/flights/Combined_Flights_2018.parquet"
flights_file2 = "/content/drive/MyDrive/data/flights/Combined_Flights_2019.parquet"
# flights_file3 = "/content/drive/MyDrive/data/flights/Combined_Flights_2020.parquet"
flights_file4 = "/content/drive/MyDrive/data/flights/Combined_Flights_2021.parquet"
# flights_file5 = "/content/drive/MyDrive/data/flights/Combined_Flights_2022.parquet"
# df1 = dd.read_parquet(flights_file1)
{x}
೦ಾ
df2 = dd.read_parquet(flights_file2)
                 df4 = dd.read_parquet(flights_file4)
                                                                                              + Código  + Texto
                                                                                                                                                                        ↑ ↓ ⊖ 💠 🗓 🗓 :
          print(df.compute())
          [ ] df = df.compute()
                 df_agg = df_agg.reset_index()
 La sesión falló. Reiniciando automáticamente.
```







Conclusiones

Luego de realizar los análisis con cada una de las librerías y con varias combinaciones de datos, podemos realizar las siguientes conclusiones de este laboratorio:

- El método polars es el más flexible y sencillo con los datos ya que este trabaja con pocos recursos tanto en programación como como en hardware
- El método pandas terminó siendo el que tuvo más complicaciones para realizar el análisis de los datos dado a que de las 4 pruebas, solo una pudo realizarse con éxito
- Los grupos de datos más flexibles de trabajar fueron los de 2018 (flights_file1)
 y 2020 (flights_file1)
- El grupo de datos con más inconvenientes para trabajar fueron los de 2019
 (flights_file2) debido a que estos mismos eran los que hacían sobrepasar el
 límite de RAM con más frecuencia a comparación de los demás grupos de datos
- El método PySpark fue el método más equilibrado en cuanto a uso de RAM con un promedio entre las 2 Gb y eficiencia de manejo de datos. Esto está demostrado con el hecho de que los métodos Pandas y Dusk superan las 7 Gb de RAM y el método Polars maneja usos entre la 1 y 2 Gb pero su manejo de datos es muy sencillo.